

技术选型决策文档

版本: v 3 . 3 | 更新日期: 2 0 2 6 - 0 5 - 1 6 1 6 : 1 8

一、选型原则

- 1. 中文优先: 金融合规审核的核心场景是中文语义理解
- 2. 渐进增强: Demo阶段零配置启动, 生产阶段平滑迁移
- 3. 接口抽象: 通过 interfaces.py 隔离具体实现, 选型变更只影响适配层
- 4. 成本可控: 优先选择按量付费的云服务, 避免固定投入
- 5. Rule First: 规则引擎优先处理确定性违规, LLM仅增强语义理解
- 6. 多模型容灾: LLM Gateway多模型路由, 消除单模型依赖

二、核心选型决策

2.1 大语言模型: 百炼 Qwen 系列 (qwen 3.6-plus 主 + qwen 3.6-flash 后备)

候选	中文理解	结构化输出	成本(1 M tokens)	数据合规	决策
qwen 3.6-plus ✅(主)	★★★★★	★★★★☆	¥ 2 /输入 ¥ 1 2 /输出	境内	主模型选定 (效果/速度/成本均衡, 多模态统一)
qwen 3.6-flash ✅(后备)	★★★★☆	★★★★☆	¥ 1.2 /输入 ¥ 7.2 /输出	境内	后备模型, 主模型熔断时自动切换
qwen-max	★★★★★	★★★★★	¥ 2.4 /输入 ¥ 9.6 /输出	境内	复杂审核备选
GPT- 4 o	★★★★☆☆	★★★★★	\$ 2.5 /输入 \$ 1 0 /输出	境外	不选
Claude Sonnet 4.5	★★★★☆☆	★★★★☆	\$ 3 /输入 \$ 1 5 /输出	境外	不选

决策理由： - 金融合规审核对中文语义理解要求极高 ("保本保息"的隐含违规含义) - qwen 3.6-plus 为多模态统一模型，支持文本+图片输入，效果/速度/成本均衡 - qwen 3.6-plus 作为主模型，同时用于推理、提取和CrossCheck - qwen 3.6-flash 作为后备模型，主模型熔断时自动切换 - 百炼 API 提供稳定的 SLA 和完善的错误码体系 - 数据不出境，满足金融行业监管要求

路由策略：通过 LLMGateway 按优先级路由，每模型独立熔断器

接口抽象：通过 interfaces.LLMProvider 隔离，切换模型只需实现新 Provider

2.2 Embedding 模型：text-embedding-v 3

候选	中文效果	维度	成本(1 M tokens)	部署方式	决策
text-embedding-v 3	★★★★★	1 0 2 4	¥ 0.7	API	选定
BGE-M 3	★★★★☆	1 0 2 4	免费(自部署)	GPU	数据敏感备选
OpenAI ada- 0 0 2	★★★☆☆	1 5 3 6	\$ 0.1	API	不选(出境)
bce-embedding	★★★★☆	7 6 8	免费(自部署)	GPU	备选

决策理由：与 Qwen 同一生态，中文语义对齐最优

2.3 向量数据库：ChromaDB → Milvus

候选	部署复杂度	分布式	过滤能力	社区	决策
ChromaDB (Demo)	★★★★★	×	★★★☆☆	活跃	Demo阶段选定
Milvus (生产)	★★★☆☆		★★★★★	非常活跃	生产替代
Qdrant	★★★★☆		★★★★☆	活跃	备选
pgvector	★★★★☆	(PG级)	★★★☆☆	一般	不选
Weaviate	★★★☆☆		★★★★☆	活跃	过于重量级

迁移路径：实现 interfaces.VectorStore 的 Milvus 适配器，零业务代码变更

2.4 关系数据库：SQLite → PostgreSQL

候选	零配置	并发写	MVCC	JSON支持	决策
SQLite (Demo)	★★★★★	串行	WAL只读并发	★★★☆☆	Demo阶段选定

候选	零配置	并发写	MVCC	JSON支持	决策
PostgreSQL  (生产)	★★☆☆☆			★★★★★(JSONB)	生产替代

迁移路径：实现 `interfaces.ReviewStorage` 的 PostgreSQL 适配器

2.5 Web框架：FastAPI + 纯HTML前端

层	框架	用途	决策理由
API + 前端	FastAPI + 纯HTML	API服务 + 前端展示	统一技术栈、前后端一体、部署简单

为什么从Gradio迁移： - Gradio 适合 ML Demo 但不适合生产 API（无认证、无限流、无版本管理） - FastAPI 适合生产 API，纯HTML前端轻量且可定制 - 统一为FastAPI + 纯HTML前端，消除双层架构的维护成本

2.6 文档解析：注册表+插件模式

格式	库	成熟度	安装方式	决策
TXT	内置	★★★★★	无依赖	选定
Markdown	内置(re)	★★★★☆	无依赖	选定
PDF	pymupdf / pdfminer	★★★★★	<code>pip install pymupdf</code>	选定(双后备)
Word	python-docx	★★★★★	<code>pip install python-docx</code>	选定
图片OCR	qwen-vl / Tesseract	★★★★☆	API / <code>pip install pytesseract</code>	选定(双后备)

扩展性：新格式只需实现 `DocumentParser` 接口并注册

2.7 安全组件

组件	选型	理由
密码哈希	PBKDF 2 -HMAC-SHA 2 5 6 (1 0 0 k iter+salt)	平衡安全与性能，生产换 bcrypt/argon 2
审计签名	HMAC-SHA 2 5 6	轻量防篡改，满足合规
API认证	API Key + RBAC(3 角色)	简单有效，生产换 OAuth 2 . 0
注入检测	2 5 种正则模式	覆盖中英文主流攻击，生产加 WAF

组件	选型	理由
幻觉检测	引用条文交叉验证	LLM输出与法规库逐条比对，移除虚假引用

2.8 可观测性

组件	选型	理由
指标	Prometheus(1 2 项)	行业标准，Grafana生态
追踪	trace_operation(进程内)	OpenTelemetry风格，生产换 OTLP
告警	AlertManager(进程内)	规则引擎+冷却，生产换 Prometheus AlertManager
日志	JSONL+HMAC+日切	结构化+防篡改，生产换 ELK/Loki

2.9 LLM Gateway：自研多模型路由网关

候选	多模型路由	独立熔断	优先级调度	角色区分	决策
自研LLMGateway ✓	✓	✓	✓(priority排序)	✓(PRIMARY/LIGHTWEIGHT/FALLBACK)	选定
LiteLLM	✓	✗	✓	✗	过于重量级
直接调用	✗	✗	✗	✗	不选(单点依赖)

决策理由： - 金融审核场景对可用性要求极高，单模型依赖不可接受 - 自研网关支持每模型独立熔断器，故障隔离 - 优先级路由：qwen 3.6 -plus(0) → qwen 3.6 -flash(5)，按priority升序尝试 - 角色区分：PRIMARY用于复杂推理，LIGHTWEIGHT用于要素提取，FALLBACK用于后备 - 无API Key时自动注册rule-engine模型，零API Key启动 - 轻量实现（~ 2 0 0 行），无额外依赖

降级链路： qwen 3.6 -plus → qwen 3.6 -flash → rule-engine(无API Key时)

2.1.0 Reranker：Cross-Encoder(有Key) / 规则重排(无Key降级)

候选	语义精度	延迟	离线可用	成本	决策
qwen 3 -rerank ✓(有Key时)	★★★★★	高	✗	¥ 0.5 /百万Token	有API Key时优先使用

候选	语义精度	延迟	离线可用	成本	决策
规则重排  (无Key降级)	★★★★☆☆	低		免费	无Key时降级方案
BM 2 5	★★☆☆☆☆	低		免费	不选(纯词频)
Cross-Encoder自部署	★★★★★★	高		GPU	过于重量级

决策理由： - RAG检索返回Top 2 0 条法规，直接送入LLM噪声过多 - Reranker将Top 2 0 重排为Top 5 ，提升法规相关性，降低LLM输入噪声 - 有API Key时使用qwen 3 -rerank Cross-Encoder语义精排，无Key时降级为规则重排（字符重叠度 + 违规关键词加权） - 生产方案：使用qwen 3 -rerank Cross-Encoder重排模型，排序精度更高

上下文扩展： Reranker在重排序后，对Top 5 结果自动召回相邻条款（前一条+后一条），标记 context_type=adjacent ，防止断章取义。相邻条款的rerank_score按 0 . 7 折减，避免干扰主排序。

2 . 1 1 Risk Engine：自研规则评分引擎

候选	可解释性	可配置	决策路由	决策理由
自研RiskEngine 	 (风险因子明细)	 (阈值可调)	 (3 级路由)	选定
简单阈值	★★☆☆☆☆		✗	过于简单
ML模型	★★☆☆☆☆	✗	✗	黑盒不可解释

决策理由： - 金融合规审核要求可解释性，黑盒评分不可接受 - 风险评分 = 违规严重度 (0 . 3 - 0 . 9) × 0 . 5 + 条文数量加权 + 规则命中加成 + 置信度调整 - 4 级风险分类：LOW(< 0 . 1) / MEDIUM(< 0 . 7) / HIGH(< 0 . 9) / CRITICAL(≥ 0 . 9) - 3 级决策路由：auto_pass / human_review / auto_block - 阈值可通过config.py配置 (RISK_AUTO_PASS_MAX, RISK_HUMAN_REVIEW_MAX)

2 . 1 2 违规类型注册表：自研动态分类体系

候选	可扩展	多对多映射	生效/失效	程序性过滤	决策
自研ViolationRegistry 				 (LLM辅助)	选定
硬编码枚举	✗	✗	✗	✗	不选(不可扩展)
纯LLM分类		✗	✗	✗	不选(不可控)

决策理由： - 金融合规审核要求违规类型可统计、可报送，硬编码不可扩展 - L 1 /L 2 分级：
L 1 (5 ~ 8 个固定大类)对应监管框架，L 2 (2 0 ~ 3 0 个半固定子类)为实际审核标签 - source
字段：标识类型来源 ("system"系统预置 / "custom"用户自定义)，支持按来源过滤和统计 -
severity默认 1 . 0 ：所有违规类型的严重度默认值为 1 . 0 ，需根据实际风险等级手动校准 - 条
款-类型多对多映射：一个条款可关联多个违规类型（如"保本保息"同时属于"绝对化用语"和"收
益承诺"） - 生效/失效时间：法规废止时标记映射失效，审核依据可追溯 - 程序性条款过滤：LLM
辅助判断条款是否属于"内容审核"范畴，过滤制度性/程序性条款 - 新法规入库标注流程：LLM辅
助建议→人工确认→自动创建映射 - JSON文件持久化，轻量无额外依赖

三、选型风险评估

选型	风险	概率	影响	缓解
百炼API	服务中断	低	高	LLM Gateway多模型路由+独立熔断+规则引擎兜底
ChromaDB	单机性能上限	中	中	迁移Milvus，接口已抽象
SQLite	写入瓶颈	中	中	迁移PostgreSQL，接口已抽象
pymupdf	PDF解析失败	低	低	pdfminer后备
qwen-vl	图片OCR不准	中	中	Tesseract后备，人工兜底
Gradio(已迁移)	前端定制受限	—	—	已迁移至FastAPI + 纯HTML前端
LLM幻觉	虚假引用条文	中	高	Validate步骤交叉验证，移除不存在的引用
Reranker	API重排失败	低	中	规则重排序降级

四、成本估算

Demo阶段（当前）

资源	规格	月成本
服务器	2 C 4 G	¥ 2 0 0
百炼API	~ 1 0 K次/月 (qwen 3 . 6 -plus ¥ 0 . 0 2 3 /次)	¥ 2 3 0
总计	—	¥ 4 3 0 /月

生产阶段（预估）

资源	规格	月成本
K 8 s集群	3 × 4 C 8 G	¥ 1 , 8 0 0
PostgreSQL RDS	2 C 4 G	¥ 4 0 0
Milvus	2 × 4 C 8 G	¥ 1 , 2 0 0
Redis	2 G	¥ 2 0 0
百炼API	~ 1 0 0 K次/月 （qwen 3 . 6 -plus ¥ 0 . 0 2 3 /次）	¥ 2 , 3 0 0
监控(Grafana+Prometheus)	2 C 4 G	¥ 4 0 0
总计	—	¥ 6 , 3 0 0 /月